



МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение
высшего образования
«Дальневосточный федеральный университет»

ИНСТИТУТ МАТЕМАТИКИ И КОМПЬЮТЕРНЫХ ТЕХНОЛОГИЙ
Кафедра математического и компьютерного моделирования

Избосарова Жасмина Олимжоновна

**РЕШЕНИЕ УРАВНЕНИЙ МАТЕМАТИЧЕСКОЙ ФИЗИКИ МЕТОДОМ PINN
И АНАЛИЗ УСТОЙЧИВОСТИ РЕШЕНИЯ МЕТОДОМ НЕЙРОННОГО
ТАНГЕНЦИАЛЬНОГО ЯДРА**

КУРСОВАЯ РАБОТА

Направление подготовки 02.03.01 сэт Сквозные цифровые технологии,
бакалавриатская программа «Математика и компьютерные науки»
Очной формы обучения

Студент гр. Б9123-02.03.01 сэт _____
(подпись)

Руководитель _____ К.С.Кузнецов
(подпись)

Оценка _____

Регистрационный № _____

(подпись) И.О. Фамилия

(подпись) И.О. Фамилия

«_____» _____ 2026 г.

«_____» _____ 2026 г.

г. Владивосток

2026

Введение

Среди современных методов численного решения уравнений в частных производных заметное место занимают Physics-Informed Neural Networks (PINN) [4], объединяющие нейросетевую аппроксимацию с явным учётом физических законов. Такой подход особенно важен в задачах, где объём наблюдаемых данных ограничен, а устойчивость и согласованность решения с математической моделью критичны.

В данной работе исследуется численное решение уравнения Курамото–Сивашинского методом PINN. Это уравнение описывает сложную нелинейную пространственно-временную динамику и используется, в частности, при моделировании фронта пламени и неустойчивых интерфейсов [2; 5]. Практический интерес к нему связан с жёсткостью и чувствительностью к численным ошибкам, что делает его удобным тестом для оценки возможностей PINN.

Исследование включает два этапа. На первом этапе решается исходное уравнение четвёртого порядка. На втором этапе выполняется понижение порядка за счёт введения вспомогательной переменной $v = \frac{\partial^2 u}{\partial x^2}$, после чего исходная задача сводится к системе уравнений второго порядка. Основная цель работы состоит в сравнении этих двух постановок и в анализе причин, по которым формально более простая система второго порядка показала худшую точность и менее устойчивую динамику обучения.

Глава 1 Математическая постановка задачи и метод решения

1.1 Математическая модель и ключевые свойства

В данной работе рассматривается одномерная задача для уравнения Курамото–Сивашинского, являющегося нелинейным эволюционным уравнением в частных производных. В используемой постановке уравнение имеет следующий вид:

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + \frac{\partial^2 u}{\partial x^2} + \frac{\partial^4 u}{\partial x^4} = 0, \quad x \in [-L, L], \quad t \in [0, T]. \quad (1)$$

Данное уравнение описывает сложную пространственно-временную динамику и включает несколько физических механизмов. Оно используется, в частности, для описания эволюции неустойчивых интерфейсов и фронтов пламени [2; 5]. Нелинейный конвективный член $u \frac{\partial u}{\partial x}$ отвечает за перенос возмущений, диффузионный член второго порядка $\frac{\partial^2 u}{\partial x^2}$ в данной записи отвечает за линейную неустойчивость, тогда как член четвёртого порядка $\frac{\partial^4 u}{\partial x^4}$ выполняет стабилизирующую функцию, подавляя рост высокочастотных возмущений.

Для рассматриваемой задачи известно точное аналитическое решение в виде бегущей волны:

$$u_{\text{exact}}(x, t) = b + \frac{15}{19} \sqrt{\frac{11}{19}} \left(-9 \tanh(k(x - bt - x_0)) + 11 \tanh^3(k(x - bt - x_0)) \right). \quad (2)$$

где параметры заданы следующим образом:

$$b = 5, \quad k = \frac{1}{2} \sqrt{\frac{11}{19}}, \quad x_0 = -12.$$

Данное решение получено путём редукции исходного уравнения в частных производных к обыкновенному дифференциальному уравнению с использованием замены переменной

$$\xi = x - bt, \quad (3)$$

что соответствует переходу к системе координат, движущейся со скоростью b , и позволяет представить решение в форме бегущей волны.

Начальные и граничные условия для рассматриваемой задачи задаются следующим образом:

$$u(0, x) = u_0(x), \quad (4)$$

$$u(t, -L) = u_1(t), \quad u(t, L) = u_2(t), \quad (5)$$

$$\frac{\partial u}{\partial x}(t, -L) = u_3(t), \quad \frac{\partial u}{\partial x}(t, L) = u_4(t). \quad (6)$$

Здесь первое выражение представляет собой *начальное условие*, определяющее распределение искомой функции $u(x, t)$ в начальный момент времени $t = 0$.

Второе и третье условия являются *граничными условиями Дирихле*, которые фиксируют значения функции на границах пространственной области $x = -L$ и $x = L$ для всех моментов времени.

Четвёртое и пятое условия представляют собой *граничные условия Неймана*, задающие значения пространственной производной $\frac{\partial u}{\partial x}$ на границах области. Эти условия описывают поток или градиент величины u через границы и играют важную роль в обеспечении корректности постановки задачи, особенно для уравнений более высокого порядка.

Совместное задание начального условия и граничных условий Дирихле и Неймана формирует корректно поставленную краевую задачу для уравнения Курамото–Сивашинского и обеспечивает единственность и устойчивость её решения.

Выбор данной задачи обусловлен наличием точного решения, что делает её удобной для верификации численных методов. В частности, это позволяет количественно оценивать точность и устойчивость метода Physics-Informed Neural Networks (PINN), а также его способность воспроизводить нелинейную динамику одномерного уравнения Курамото–Сивашинского в условиях ограниченного объёма данных.

1.2 Описание метода Physics-Informed Neural Networks

Метод Physics-Informed Neural Networks (PINN) представляет собой подход, в котором нейронная сеть используется для аппроксимации решения дифференциального уравнения с явным учётом физических законов, задаваемых этим уравнением. В базовой постановке искомая функция приближается полносвязной нейронной сетью, а обучение осуществляется посредством минимизации составной функции потерь, включающей как вклад невязки дифференциального уравнения, так и отклонения от начальных и граничных условий [4].

Реализация выполнена в среде Python с применением библиотек автоматического дифференцирования и градиентной оптимизации. Общая методология обучения не зависит от конкретного вычислительного эксперимента и включает три ключевых этапа:

- формирование точек начального условия (IC), граничных условий Дирихле и Неймана (BC), а также внутренних коллокационных точек;
- вычисление невязки уравнения и граничных ограничений посредством автоматического дифференцирования;
- минимизацию взвешенной составной функции потерь.

Искомая функция аппроксимируется полносвязной нейронной сетью прямого распространения:

$$u_{\theta}(t, x) \approx u(t, x),$$

где θ — вектор параметров сети.

Входными параметрами сети являются пространственная и временная координаты, подвергнутые предварительному преобразованию, а выходом — значение искомой функции. Архитектура сети подбирается таким образом, чтобы обеспечить достаточную выразительную способность для аппроксимации нелинейного решения с выраженными пространственно-временными структурами.

Обучение модели осуществляется на совокупности точек рисунок 1, распределённых в области определения задачи. Используются три

типа точек: точки начального условия, точки граничных условий и внутренние коллокационные точки, в которых контролируется выполнение дифференциального уравнения.




Рисунок 1 – Обучающая выборка

Внутренние точки используются для минимизации невязки дифференциального уравнения, получаемой путём подстановки нейросетевой аппроксимации в исходное уравнение. Производные по пространственной и временной переменным, включая старшие производные, вычисляются с использованием автоматического дифференцирования.

Невязка уравнения имеет вид:

$$r_{\theta}(t, x) = \frac{\partial u_{\theta}}{\partial t} + u_{\theta} \frac{\partial u_{\theta}}{\partial x} + \frac{\partial^2 u_{\theta}}{\partial x^2} + \frac{\partial^4 u_{\theta}}{\partial x^4}.$$

Функция потерь формируется как сумма нескольких слагаемых:

$$\mathcal{L} = \lambda_r \mathcal{L}_r + \lambda_0 \mathcal{L}_0 + \lambda_D \mathcal{L}_D + \lambda_N \mathcal{L}_N,$$

где

$$\mathcal{L}_r = \frac{1}{N_r} \sum_{i=1}^{N_r} |r_{\theta}(t_i, x_i)|^2,$$

$$\mathcal{L}_0 = \frac{1}{N_0} \sum_{i=1}^{N_0} |u_\theta(0, x_i) - u_0(x_i)|^2,$$

$$\mathcal{L}_D = \frac{1}{N_b} \sum_{i=1}^{N_b} (|u_\theta(t_i, -L) - u_1(t_i)|^2 + |u_\theta(t_i, L) - u_2(t_i)|^2).$$

$$\mathcal{L}_N = \frac{1}{N_b} \sum_{i=1}^{N_b} \left(\left| \frac{\partial u_\theta}{\partial x}(t_i, -L) - u_3(t_i) \right|^2 + \left| \frac{\partial u_\theta}{\partial x}(t_i, L) - u_4(t_i) \right|^2 \right).$$

Здесь N_r , N_0 , N_b — количество внутренних, начальных и граничных точек соответственно, а λ_r , λ_0 , λ_D , λ_N — весовые коэффициенты.

Обучение сводится к задаче оптимизации:

$$\theta^* = \arg \min_{\theta} \mathcal{L}.$$

С целью повышения качества восстановления решения в работе применяется нормирование искомой функции:

$$u(t, x) = u_s \cdot \tilde{u}(t, x),$$

где u_s — масштабный коэффициент.

Для рассматриваемой задачи важна корректная передача высокочастотных компонент и локальных перепадов решения. Однако классические полносвязные сети проявляют эффект спектрального смещения (spectral bias), то есть склонность сначала аппроксимировать низкочастотные составляющие [1; 3]. Для ослабления этого эффекта входные переменные дополнительно преобразуются с помощью Фурье-кодирования:

$$\gamma(t) = [\sin(2\pi B_t t), \cos(2\pi B_t t)], \quad \gamma(x) = [\sin(2\pi B_x x), \cos(2\pi B_x x)].$$

Конкретные параметры вычислительного эксперимента, пространственно-временная область, длительность обучения и детали сравнения с точным решением приведены в главе 2.

Глава 2 Этап 1: базовый вычислительный эксперимент

2.1 Формирование обучающего множества и коллокация

Вычислительный эксперимент для решения уравнения Курамото–Сивашинского проводился в прямоугольной пространственно-временной области $(t, x) \in [0, 4] \times [-30, 30]$. Обучающее множество строилось по общей схеме, описанной в разделе 1.2: точки начального условия задавались на слое $t = 0$, точки граничных условий — на границах $x = -30$ и $x = 30$, а внутренние коллокационные точки распределялись внутри всей области. Во всех трёх группах использовалось случайное равномерное распределение в соответствующих подмножествах области определения. Схематически распределение точек показано на рисунок 1.

2.2 Параметры базовой модели

В качестве базовой модели использовалась полносвязная нейронная сеть $u_\theta(t, x)$ с нормированием выходной переменной и Фурье-кодированием входов, введёнными в разделе 1.2. Такое сочетание позволяло стабилизировать масштаб выходной функции и повысить способность сети передавать локальные пространственные особенности точного решения.

Обучение базовой модели проводилось до 13000 эпох. Для анализа динамики сходимости и эволюции аппроксимации дополнительно рассматривались промежуточные состояния после 3000 ,7000 и 10000 эпох. Качество восстановления оценивалось сравнением с точным аналитическим решением на характерных временных срезах $t = 0$ и $t = 4$.

2.3 Анализ динамики обучения и эволюция аппроксимации

Анализ графиков сходимости (компонентов функции потерь и общей ошибки) позволяет глубоко понять нелинейную динамику обучения PINN. Обучение уравнения КС является жесткой задачей оптимизации. Слагаемые функции потерь (невязка PDE, начальные и граничные условия) имеют разную

чувствительность. В частности, член $\frac{\partial^4 u_\theta}{\partial x^4}$ вносит огромный вклад в градиенты на ранних этапах, что может приводить к дисбалансу оптимизации.

Эволюцию нейросетевого решения можно разделить на три характерные фазы:

Первая фаза — инициализация и тепловой дрейф (начальные эпохи, рисунок 2):




Рисунок 2 – Начальная эпоха

На старте обучения сеть инициализирована случайными весами. Предсказание (синяя линия) представляет собой константу или функцию с минимальной амплитудой, которая совершенно не совпадает с точным решением (оранжевая пунктирная линия) ни при $t = 0$, ни при $t = 4$. Модель пытается минимизировать общую ошибку тривиальным путём, сглаживая градиенты, так как штраф за неверные старшие производные u_{xxxx} на этом этапе подавляет штраф за несовпадение амплитуд.

Вторая фаза — структурное выравнивание (промежуточные эпохи, рисунок 4, рисунок 3, рисунок 5):




Рисунок 3 – 3000 эпоха

По мере оптимизации сеть начинает улавливать глобальную геометрию решения. Проявляется характерный профиль: пик и следующий за ним провал. Однако на этом этапе наблюдаются фазовые сдвиги и ошибки амплитуды. Модель успешно выучила начальное условие при $t = 0$, но физическая невязка




Рисунок 4 – 7000 эпоха




Рисунок 5 – 10000 эпоха

(уравнение) еще не до конца сбалансирована. Конвективный член uu_x и баланс диффузии сопротивляются корректному переносу структуры во времени, из-за чего на срезе $t = 4$ предсказание может отставать или опережать аналитическую бегущую волну.

Третья фаза — асимптотическая сходимость (итоговая аппроксимация, рисунок 6):




Рисунок 6 – 13000 эпоха

На финальных стадиях градиенты всех компонент функции потерь приходят к равновесию. Нейросеть идеально восстанавливает решение. Синяя кривая практически полностью сливается с эталонной оранжевой кривой на обоих временных срезах.

В результате обучения была достигнута хорошая геометрическая точность: воспроизведён нелинейный профиль решения вида $\tanh / \tanh^3$ с сохранением

масштаба амплитуды.

2.4 Анализ ошибки

Как следует из рисунок 7, динамика сходимости различных компонент функции потерь существенно отличается. На начальном этапе обучения модель демонстрирует более точную аппроксимацию начального условия по сравнению с условиями Неймана. Это проявляется в более быстром убывании соответствующей компоненты функции потерь.

Однако по мере продолжения обучения наблюдается изменение характера сходимости: условия Неймана демонстрируют более устойчивое поведение и меньшую чувствительность к итерационным колебаниям. В то же время аппроксимация начального условия становится менее стабильной, что выражается в появлении значительных и частых осцилляций ошибки. Подобное поведение может свидетельствовать о переобучении модели по данной компоненте.




Рисунок 7 – Динамика компонент функции потерь, соответствующих различным условиям задачи

Суммарная функция потерь (рисунок 8) в целом демонстрирует хорошую сходимость: значение ошибки монотонно убывает на протяжении большей части процесса обучения и достигает порядка 10^{-5} , что можно считать качественным результатом аппроксимации. Тем не менее, на заключительном этапе обучения наблюдается рост числа осцилляций, что обусловлено увеличением вклада одной из граничных компонент ошибки. Это указывает на ухудшение обобщающей способности модели в данной области и возможную

необходимость дополнительной регуляризации или балансировки весов в функции потерь.




Рисунок 8 – Динамика суммарной функции потерь

Глава 3 Этап 2: понижение порядка и анализ деградации точности

3.1 Модификация постановки задачи и варианты архитектур PINN

В рамках исследования методов повышения точности аппроксимации и ускорения сходимости физически-информированных нейронных сетей (PINN) была выдвинута гипотеза о целесообразности понижения порядка старшей пространственной производной в исходном уравнении. Для этого была введена дополнительная вспомогательная переменная:

$$v = \frac{\partial^2 u}{\partial x^2}$$

Данная подстановка преобразует исходное уравнение с производными четвёртого порядка в систему уравнений не выше второго порядка:

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v + \frac{\partial^2 v}{\partial x^2} = 0, \quad v - \frac{\partial^2 u}{\partial x^2} = 0.$$

Теоретически такая замена должна была упростить вычисления, так как автоматическое дифференцирование высоких порядков часто приводит к вычислительной неустойчивости, затуханию градиентов и высокой чувствительности модели к гиперпараметрам.

В результате функционал потерь был расширен: в него была включена дополнительная невязка

$$v - \frac{\partial^2 u}{\partial x^2} = 0,$$

обеспечивающая выполнение условия согласования между исходной функцией $u(t, x)$ и новой переменной $v(t, x)$. Для решения модифицированной системы были спроектированы и протестированы три различные архитектуры:

- **Единая нейронная сеть с двумя выходами (two_output):** Отображение пространства входов в двумерный выход (u, v) с общим скрытым представлением.
- **Две независимые нейронные сети (two_models):** Полное разделение

параметров, где функции u и v аппроксимируются изолированными сетями.

- **Сеть с общим стволом и раздельными ветвями (shared_trunk):** Гибридный подход, при котором начальные слои извлекают общие физические закономерности, а независимые «головы» адаптируются к спецификам u и v .

3.2 Анализ динамики обучения и графиков сходимости

Эмпирическая проверка предложенных подходов выявила ряд непредвиденных оптимизационных трудностей. Анализ полученных графиков позволяет сделать следующие выводы:

- **Сравнение сходимости:** На сводном графике функции потерь отчетливо видно, что базовая модель из первого этапа (stage1_start, синий пунктир) демонстрирует стабильную сходимость, достигая значений порядка 10^{-5} . В то же время все три модифицированные архитектуры второго этапа быстро выходят на плато. Итоговые значения функции потерь для них стабилизируются на уровне $1.4 \cdot 10^{-4} - 1.5 \cdot 10^{-4}$, что на порядок хуже результатов исходной модели. Рисунок 9
- **Компоненты функции потерь:** Анализ графика *loss components* (на примере shared_trunk) показывает, что стагнация общего лосса продиктована невязкой самого дифференциального уравнения (L_r). В то время как ошибки начальных и граничных условий продолжают снижаться, хотя и сопровождаются высокочастотными осцилляциями, невязка PDE упирается в выраженный оптимизационный барьер.
- **Эволюция аппроксимации (u и v):** Визуальный анализ предсказаний на различных временных шагах $t = 0.00$, $t = 2.00$ и $t = 4.00$ демонстрирует причину этой стагнации. Если профиль основной функции $u(t, x)$ сеть улавливает сравнительно неплохо, то аппроксимация вспомогательной переменной $v(t, x)$ сталкивается с серьёзными проблемами. На графиках видно расхождение между предсказанием и точным решением: нейронная сеть генерирует паразитные осцилляции и сглаживает острые пики $v(t, x)$ даже на поздних этапах обучения, вплоть до 13000-й эпохи.




Рисунок 9 – Сравнение ошибок аппроксимации четырёх моделей

3.3 Почему введение вспомогательной переменной привело к осцилляциям

Наблюдаемая деградация качества во втором этапе указывает на то, что формальное понижение порядка производных не эквивалентно упрощению самой задачи оптимизации. Напротив, введение переменной v сделало функцию потерь более жёсткой: сеть должна одновременно согласовать поведение u , восстановить менее гладкую функцию v и выполнить связь $v = \frac{\partial^2 u}{\partial x^2}$. Эти требования действуют на разных масштабах и порождают градиенты различной величины, что типично для жёстких PINN-задач [6; 7].

Наиболее правдоподобная гипотеза состоит в том, что именно ошибка аппроксимации v начинает доминировать в функции потерь. Величина v является второй производной u , а значит, чувствительна к малым локальным отклонениям сети и содержит более выраженные высокочастотные компоненты. Даже небольшая ошибка в восстановлении u приводит к существенно большей ошибке в v , после чего слагаемое согласования $v - \frac{\partial^2 u}{\partial x^2}$ начинает генерировать крупные и быстро меняющиеся градиенты.

В связанных архитектурах это приводит к тому, что сеть фактически пытается «подстроить» u под уже неточную аппроксимацию v . Иными словами, ошибка во вспомогательной переменной сбивает основную сеть с толку: параметры обновляются не только в направлении уменьшения невязки исходного уравнения, но и в направлении компенсации шумной ошибки во второй производной. Такая конкуренция градиентов естественным образом объясняет появление осцилляций, ранний выход на плато и ухудшение итоговой

точности по сравнению с прямым решением исходного уравнения четвёртого порядка.

3.4 Выводы: деградация эффективности при усложнении системы

Опираясь на количественные метрики и визуальный анализ, можно констатировать, что метод понижения порядка производной за счёт введения вспомогательной переменной оказался **менее эффективным**, чем прямая аппроксимация исходного уравнения. Деградация предсказательной способности и качества сходимости обусловлена следующими факторами:

1. **Конкуренция градиентов и жёсткость оптимизации:** Введение дополнительного условия согласования $v - \frac{\partial^2 u}{\partial x^2} = 0$ значительно усложнило ландшафт функции потерь. Модель была вынуждена балансировать между минимизацией невязки самого уравнения и выполнением жёсткой структурной связи между двумя выходами, что привело к конфликту градиентов при оптимизации [6; 7].
2. **Доминирование ошибки во вспомогательной переменной:** Поскольку v является второй производной u , ошибка её аппроксимации накапливается быстрее и начинает доминировать в составной функции потерь. В результате обновления параметров всё сильнее определяются не динамикой исходной задачи, а попыткой согласовать шумную оценку v .
3. **Проблема масштабов и гладкости:** Функции u и v имеют различный масштаб значений и разную степень гладкости, что затрудняет их совместное обучение даже при использовании отдельных выходных слоёв или полностью независимых сетей.

Список литературы

1. Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains / M. Tancik [и др.] // *Advances in Neural Information Processing Systems* 33. — 2020. — С. 7537—7547.
2. *Kuramoto Y.* Diffusion-Induced Chaos in Reaction Systems // *Progress of Theoretical Physics Supplement*. — 1978. — Т. 64. — С. 346—367.
3. On the Spectral Bias of Neural Networks / N. Rahaman [и др.] // *Proceedings of the 36th International Conference on Machine Learning*. Т. 97. — 2019. — С. 5301—5310. — (Proceedings of Machine Learning Research).
4. *Raissi M., Perdikaris P., Karniadakis G. E.* Physics-Informed Neural Networks: A Deep Learning Framework for Solving Forward and Inverse Problems Involving Nonlinear Partial Differential Equations // *Journal of Computational Physics*. — 2019. — Т. 378. — С. 686—707. — DOI: 10.1016/j.jcp.2018.10.045.
5. *Sivashinsky G. I.* Nonlinear Analysis of Hydrodynamic Instability in Laminar Flames—I. Derivation of Basic Equations // *Acta Astronautica*. — 1977. — Т. 4, № 11/12. — С. 1177—1206.
6. *Wang S., Teng Y., Perdikaris P.* Understanding and Mitigating Gradient Flow Pathologies in Physics-Informed Neural Networks // *SIAM Journal on Scientific Computing*. — 2021. — Т. 43, № 5. — A3055—A3081. — DOI: 10.1137/20M1318043.
7. *Wang S., Yu X., Perdikaris P.* When and Why PINNs Fail to Train: A Neural Tangent Kernel Perspective // *Journal of Computational Physics*. — 2022. — Т. 449. — С. 110768. — DOI: 10.1016/j.jcp.2021.110768.