



МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение
высшего образования
«Дальневосточный федеральный университет»

ИНСТИТУТ МАТЕМАТИКИ И КОМПЬЮТЕРНЫХ ТЕХНОЛОГИЙ
Кафедра математического и компьютерного моделирования

Избосарова Жасмина Олимжоновна

**РЕШЕНИЕ УРАВНЕНИЙ МАТЕМАТИЧЕСКОЙ ФИЗИКИ МЕТОДОМ PINN
И АНАЛИЗ УСТОЙЧИВОСТИ РЕШЕНИЯ МЕТОДОМ НЕЙРОННОГО
ТАНГЕНЦИАЛЬНОГО ЯДРА**

КУРСОВАЯ РАБОТА

Направление подготовки 02.03.01 сэт Сквозные цифровые технологии,
бакалавриатская программа «Математика и компьютерные науки»
Очной формы обучения

Студент гр. Б9123-02.03.01 сэт _____
(подпись)

Руководитель _____ К.С.Кузнецов
(подпись)

Оценка _____

Регистрационный № _____

(подпись) И.О. Фамилия

(подпись) И.О. Фамилия

«_____» _____ 2026 г.

«_____» _____ 2026 г.

г. Владивосток

2026

Введение

Среди современных методов численного решения уравнений в частных производных заметное место занимают Physics-Informed Neural Networks (PINN) [4], объединяющие нейросетевую аппроксимацию с явным учётом физических законов. Такой подход особенно важен в задачах, где объём наблюдаемых данных ограничен, а устойчивость и согласованность решения с математической моделью критичны.

В данной работе исследуется численное решение уравнения Курамото–Сивашинского методом PINN. Это уравнение описывает сложную нелинейную пространственно-временную динамику и используется, в частности, при моделировании фронта пламени и неустойчивых интерфейсов [2; 5]. Практический интерес к нему связан с жёсткостью и чувствительностью к численным ошибкам, что делает его удобным тестом для оценки возможностей PINN.

Исследование включает два этапа. На первом этапе решается исходное уравнение четвёртого порядка. На втором этапе выполняется понижение порядка за счёт введения вспомогательной переменной $v = \frac{\partial^2 u}{\partial x^2}$, после чего исходная задача сводится к системе уравнений второго порядка. Основная цель работы состоит в сравнении этих двух постановок и в анализе причин, по которым формально более простая система второго порядка показала худшую точность и менее устойчивую динамику обучения.

Глава 1 Математическая постановка задачи и метод решения

1.1 Математическая модель и ключевые свойства

В данной работе рассматривается одномерная задача для уравнения Курамото–Сивашинского, являющегося нелинейным эволюционным уравнением в частных производных. В используемой постановке уравнение имеет вид формула (1.1):

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + \frac{\partial^2 u}{\partial x^2} + \frac{\partial^4 u}{\partial x^4} = 0, \quad x \in [-L, L], \quad t \in [0, T]. \quad (1.1)$$

Данное уравнение описывает сложную пространственно-временную динамику и включает несколько физических механизмов. Оно используется, в частности, для описания эволюции неустойчивых интерфейсов и фронтов пламени [2; 5]. Нелинейный конвективный член $u \frac{\partial u}{\partial x}$ отвечает за перенос возмущений, диффузионный член второго порядка $\frac{\partial^2 u}{\partial x^2}$ в данной записи отвечает за линейную неустойчивость, тогда как член четвёртого порядка $\frac{\partial^4 u}{\partial x^4}$ выполняет стабилизирующую функцию, подавляя рост высокочастотных возмущений.

Для рассматриваемой задачи известно точное аналитическое решение в виде бегущей волны формула (1.2):

$$u_{\text{exact}}(x, t) = b + \frac{15}{19} \sqrt{\frac{11}{19}} \left(-9 \tanh(k(x - bt - x_0)) + 11 \tanh^3(k(x - bt - x_0)) \right). \quad (1.2)$$

где параметры заданы в формула (1.3):

$$b = 5, \quad k = \frac{1}{2} \sqrt{\frac{11}{19}}, \quad x_0 = -12. \quad (1.3)$$

Данное решение получено путём редукции исходного уравнения в частных производных к обыкновенному дифференциальному уравнению с использованием замены переменной формула (1.4):

$$\xi = x - bt. \quad (1.4)$$

что соответствует переходу к системе координат, движущейся со скоростью

b , и позволяет представить решение в форме бегущей волны.

Начальные и граничные условия для рассматриваемой задачи задаются соотношениями формулы (1.5)–(1.7):

$$u(0, x) = u_0(x). \quad (1.5)$$

$$u(t, -L) = u_1(t), \quad u(t, L) = u_2(t). \quad (1.6)$$

$$\frac{\partial u}{\partial x}(t, -L) = u_3(t), \quad \frac{\partial u}{\partial x}(t, L) = u_4(t). \quad (1.7)$$

Начальное условие задаётся формула (1.5) и определяет распределение искомой функции $u(x, t)$ в начальный момент времени $t = 0$.

Граничные условия Дирихле задаются формула (1.6); они фиксируют значения функции на границах пространственной области $x = -L$ и $x = L$ для всех моментов времени.

Условия Неймана задаются формула (1.7) и определяют значения пространственной производной $\frac{\partial u}{\partial x}$ на границах области. Эти условия описывают поток или градиент величины u через границы и играют важную роль в обеспечении корректности постановки задачи, особенно для уравнений более высокого порядка.

Совместное задание начального условия и граничных условий Дирихле и Неймана формирует корректно поставленную краевую задачу для уравнения Курамото–Сивашинского и обеспечивает единственность и устойчивость её решения.

Выбор данной задачи обусловлен наличием точного решения, что делает её удобной для верификации численных методов. В частности, это позволяет количественно оценивать точность и устойчивость метода Physics-Informed Neural Networks (PINN), а также его способность воспроизводить нелинейную динамику одномерного уравнения Курамото–Сивашинского в условиях ограниченного объёма данных.

1.2 Описание метода Physics-Informed Neural Networks

Метод Physics-Informed Neural Networks (PINN) представляет собой подход, в котором нейронная сеть используется для аппроксимации

решения дифференциального уравнения с явным учётом физических законов, задаваемых этим уравнением. В базовой постановке искомая функция приближается полносвязной нейронной сетью, а обучение осуществляется посредством минимизации составной функции потерь, включающей как вклад невязки дифференциального уравнения, так и отклонения от начальных и граничных условий [4].

Реализация выполнена в среде Python с применением библиотек автоматического дифференцирования и градиентной оптимизации. Общая методология обучения не зависит от конкретного вычислительного эксперимента и включает три ключевых этапа:

- формирование точек начального условия (IC), граничных условий Дирихле и Неймана (BC), а также внутренних коллокационных точек;
- вычисление невязки уравнения и граничных ограничений посредством автоматического дифференцирования;
- минимизацию взвешенной составной функции потерь.

Искомая функция аппроксимируется полносвязной нейронной сетью прямого распространения формула (1.8):

$$u_{\theta}(t, x) \approx u(t, x), \quad (1.8)$$

где θ — вектор параметров сети.

Входными параметрами сети являются пространственная и временная координаты, подвергнутые предварительному преобразованию, а выходом — значение искомой функции. Архитектура сети подбирается таким образом, чтобы обеспечить достаточную выразительную способность для аппроксимации нелинейного решения с выраженными пространственно-временными структурами.

Обучение модели осуществляется на совокупности точек рисунок 1, распределённых в области определения задачи. Используются три типа точек: точки начального условия, точки граничных условий и внутренние коллокационные точки, в которых контролируется выполнение дифференциального уравнения.

Внутренние точки используются для минимизации невязки дифференциального уравнения, получаемой путём подстановки нейросетевой



Рисунок 1 – Обучающая выборка

аппроксимации в исходное уравнение. Производные по пространственной и временной переменным, включая старшие производные, вычисляются с использованием автоматического дифференцирования.

Невязка уравнения имеет вид формула (1.9):

$$r_{\theta}(t, x) = \frac{\partial u_{\theta}}{\partial t} + u_{\theta} \frac{\partial u_{\theta}}{\partial x} + \frac{\partial^2 u_{\theta}}{\partial x^2} + \frac{\partial^4 u_{\theta}}{\partial x^4}. \quad (1.9)$$

Функция потерь формируется как сумма нескольких слагаемых формулы (1.10)–(1.14):

$$\mathcal{L} = \lambda_r \mathcal{L}_r + \lambda_0 \mathcal{L}_0 + \lambda_D \mathcal{L}_D + \lambda_N \mathcal{L}_N, \quad (1.10)$$

где

$$\mathcal{L}_r = \frac{1}{N_r} \sum_{i=1}^{N_r} |r_{\theta}(t_i, x_i)|^2, \quad (1.11)$$

$$\mathcal{L}_0 = \frac{1}{N_0} \sum_{i=1}^{N_0} |u_{\theta}(0, x_i) - u_0(x_i)|^2, \quad (1.12)$$

$$\mathcal{L}_D = \frac{1}{N_b} \sum_{i=1}^{N_b} (|u_{\theta}(t_i, -L) - u_1(t_i)|^2 + |u_{\theta}(t_i, L) - u_2(t_i)|^2). \quad (1.13)$$

$$\mathcal{L}_N = \frac{1}{N_b} \sum_{i=1}^{N_b} \left(\left| \frac{\partial u_\theta}{\partial x}(t_i, -L) - u_3(t_i) \right|^2 + \left| \frac{\partial u_\theta}{\partial x}(t_i, L) - u_4(t_i) \right|^2 \right). \quad (1.14)$$

Здесь N_r , N_0 , N_b — количество внутренних, начальных и граничных точек соответственно, а λ_r , λ_0 , λ_D , λ_N — весовые коэффициенты.

Каждая из компонент в формула (1.10) имеет самостоятельный физико-математический смысл. Слагаемое формула (1.11) отвечает за выполнение самого дифференциального уравнения во внутренних коллокационных точках области и тем самым обеспечивает физическую согласованность нейросетевой аппроксимации. Компонента формула (1.12) контролирует точность воспроизведения начального условия и заставляет сеть корректно восстанавливать профиль решения в момент времени $t = 0$. Слагаемое формула (1.13) штрафует отклонения значений $u_\theta(t, x)$ от заданных граничных условий Дирихле на концах пространственного интервала, то есть фиксирует значения решения на границе области. Наконец, компонента формула (1.14) отвечает за выполнение граничных условий Неймана и согласует значения пространственной производной $\frac{\partial u_\theta}{\partial x}$ на границах с предписанными функциями $u_3(t)$ и $u_4(t)$. Таким образом, минимизация полной функции потерь означает одновременное стремление сети удовлетворить уравнению, начальному условию и обоим типам граничных ограничений, а весовые коэффициенты позволяют регулировать относительный вклад каждой из этих составляющих в процесс обучения.

Обучение сводится к задаче оптимизации формула (1.15):

$$\theta^* = \arg \min_{\theta} \mathcal{L}. \quad (1.15)$$

С целью повышения качества восстановления решения в работе применяется нормирование искомой функции формула (1.16):

$$u(t, x) = u_s \cdot \tilde{u}(t, x), \quad (1.16)$$

где u_s — масштабный коэффициент.

Для рассматриваемой задачи важна корректная передача высокочастотных компонент и локальных перепадов решения. Однако классические полносвязные сети проявляют эффект спектрального смещения (spectral bias), то есть склонность сначала аппроксимировать низкочастотные составляющие

[1; 3]. Для ослабления этого эффекта входные переменные дополнительно преобразуются с помощью Фурье-кодирования формула (1.17):

$$\gamma(t) = [\sin(2\pi B_t t), \cos(2\pi B_t t)], \quad \gamma(x) = [\sin(2\pi B_x x), \cos(2\pi B_x x)]. \quad (1.17)$$

Конкретные параметры вычислительного эксперимента, пространственно-временная область, длительность обучения и детали сравнения с точным решением приведены в главе 2.

Глава 2 Этап 1: базовый вычислительный эксперимент

2.1 Формирование обучающего множества и коллокация

Вычислительный эксперимент для решения уравнения Курамото–Сивашинского проводился в прямоугольной пространственно-временной области $(t, x) \in [0, 4] \times [-30, 30]$. Обучающее множество строилось по общей схеме, описанной в разделе 1.2: точки начального условия задавались на слое $t = 0$, точки граничных условий — на границах $x = -30$ и $x = 30$, а внутренние коллокационные точки распределялись внутри всей области. Во всех трёх группах использовалось случайное равномерное распределение в соответствующих подмножествах области определения. Схематически распределение точек показано на рисунок 1.

2.2 Параметры базовой модели

В качестве базовой модели использовалась полносвязная нейронная сеть $u_\theta(t, x)$ с нормированием выходной переменной и Фурье-кодированием входов, введёнными в разделе 1.2. Такое сочетание позволяло стабилизировать масштаб выходной функции и повысить способность сети передавать локальные пространственные особенности точного решения.

Обучение базовой модели проводилось до 13000 эпох. Для анализа динамики сходимости и эволюции аппроксимации дополнительно рассматривались промежуточные состояния после 3000, 7000 и 10000 эпох. Качество восстановления оценивалось сравнением с точным аналитическим решением на характерных временных срезах $t = 0$ и $t = 4$.

2.3 Анализ динамики обучения и эволюция аппроксимации

Графики рисунки 2–6 показывают типичную для PINN последовательность этапов обучения. На начальной стадии предсказание остаётся сглаженным и существенно отличается от точного решения как по амплитуде, так и по положению фронта. Такое поведение согласуется с доминированием

residual-компоненты, содержащей производную четвёртого порядка: на ранних итерациях сеть предпочитает низкочастотные профили с малой кривизной.




Рисунок 2 – Начальная эпоха

На промежуточных итерациях модель начинает воспроизводить глобальную геометрию бегущей волны: формируются основной пик и следующая за ним впадина, уменьшается ошибка на срезе $t = 0$, а профиль при $t = 4$ приобретает корректное направление переноса. В то же время сохраняются фазовый сдвиг и ошибка амплитуды, что указывает на неполное согласование между выполнением уравнения и воспроизведением временной эволюции решения.




Рисунок 3 – 3000-я эпоха




Рисунок 4 – 7000-я эпоха

На заключительной стадии предсказание практически совпадает с точным решением на рассматриваемых временных срезах. Модель корректно воспроизводит нелинейный профиль типа $\tanh / \tanh^3$, пространственный сдвиг волны и масштаб амплитуды.




Рисунок 5 – 10000-я эпоха




Рисунок 6 – 13000-я эпоха

2.4 Анализ ошибки

Как показывает рисунок 7, компоненты функции потерь убывают с различной скоростью. На ранних итерациях ошибка по начальному условию снижается быстрее, чем ошибка, связанная с граничными ограничениями. На поздней стадии компонент, соответствующий условиям Неймана, демонстрирует более ровную динамику и меньшую чувствительность к высокочастотным колебаниям, чем ошибка по начальному условию. В пределах данного эксперимента его можно рассматривать как более устойчивый ориентир при анализе сходимости отдельных частей функционала.

Суммарная функция потерь (рисунок 8) в целом демонстрирует хорошую сходимость: значение ошибки монотонно убывает на протяжении большей части процесса обучения и достигает порядка 10^{-5} , что соответствует качественной аппроксимации. На заключительном участке появляются локальные осцилляции, согласующиеся с ростом вклада одной из граничных компонент. Это указывает на дисбаланс между отдельными частями функционала и делает оправданным дополнительное перевзвешивание условий в функции потерь.




Рисунок 7 – Динамика компонент функции потерь, соответствующих различным условиям задачи




Рисунок 8 – Динамика суммарной функции потерь

Глава 3 Этап 2: понижение порядка и анализ деградации точности

3.1 Модификация постановки задачи и варианты архитектур PINN

На втором этапе проверялась гипотеза о том, что понижение порядка старшей пространственной производной может упростить обучение PINN. Для этого была введена дополнительная вспомогательная переменная формула (3.1):

$$v = \frac{\partial^2 u}{\partial x^2} \quad (3.1)$$

Данная подстановка преобразует исходное уравнение с производными четвёртого порядка в систему уравнений не выше второго порядка, задаваемую формулы (3.2) и (3.3):

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v + \frac{\partial^2 v}{\partial x^2} = 0. \quad (3.2)$$

$$v - \frac{\partial^2 u}{\partial x^2} = 0. \quad (3.3)$$

Мотивацией такой замены было исключение прямого вычисления производной четвёртого порядка, которое в PINN часто сопровождается жёсткостью градиентов и повышенной чувствительностью к гиперпараметрам. Вместе с тем новая постановка не сводится к упрощению оптимизации: она вводит дополнительное поле $v(t, x)$ и условие согласования формула (3.3), так что сеть должна одновременно восстановить $u(t, x)$, $v(t, x)$ и их взаимосвязь во всей области.

Для решения модифицированной системы были рассмотрены три архитектуры:

- **Единая нейронная сеть с двумя выходами (two_output):** Отображение пространства входов в двумерный выход (u, v) с общим скрытым представлением.
- **Две независимые нейронные сети (two_models):** Полное разделение параметров, где функции u и v аппроксимируются изолированными сетями.

- **Сеть с общим стволом и отдельными ветвями (shared_trunk):** Гибридный подход, при котором начальные слои извлекают общие физические закономерности, а независимые «головы» адаптируются к спецификам u и v .

3.2 Динамика обучения и сравнительный анализ архитектур

На рисунок 9 для всех архитектур второго этапа наблюдается одна и та же закономерность. На начальных итерациях total loss быстро убывает, затем после примерно $3 \cdot 10^3 - 4 \cdot 10^3$ шагов темп сходимости резко снижается, и траектории переходят в режим плато. Финальные значения total loss стабилизируются на уровне $1.4 \cdot 10^{-4} - 1.5 \cdot 10^{-4}$, тогда как базовая модель первого этапа достигает уровня порядка 10^{-5} . Следовательно, понижение порядка производной не устранило оптимизационный барьер, а перенесло его в новую постановку.




Рисунок 9 – Сравнение ошибок аппроксимации четырёх моделей

Сравнение кривых total loss на рисунки 10–12 показывает, что среди архитектур второго этапа наиболее ровную траекторию и наименьший финальный уровень ошибки демонстрирует shared_trunk. Архитектура two_output близка к ней по уровню ошибки, но сохраняет более регулярные всплески. Наиболее выраженные осцилляции наблюдаются у two_models, что указывает на наименьшую устойчивость этой схемы.

Графики компонент функции потерь на рисунки 13–15 показывают, что во всех трёх случаях ключевым ограничением остаётся невязка уравнения L_r . Компоненты начального условия L_0 и граничных условий L_b убывают быстрее и к концу обучения оказываются на один–два порядка ниже. Тем самым




Рисунок 10 – Общая ошибка гибридной модели с общим стволом




Рисунок 11 – Общая ошибка модели с двумя выходами




Рисунок 12 – Общая ошибка модели с двумя независимыми нейронными сетями

общая закономерность обучения моделей второго этапа состоит в следующем: начальное снижение total loss достигается за счёт быстрого уменьшения ошибок по данным и граничным ограничениям, после чего дальнейшая сходимость определяется residual-компонентой и необходимостью согласования полей u и v .




Рисунок 13 – Компоненты функции потерь гибридной модели с общим стволом




Рисунок 14 – Компоненты функции потерь модели с двумя выходами

Пики на кривых total loss и отдельных компонент возникают при попытках дальнейшего уменьшения L_r после выхода на плато. Их наибольшая амплитуда в two_models согласуется с тем, что две независимые сети должны синхронизироваться только через функционал потерь. В two_output этот конфликт выражен слабее, однако общее скрытое представление должно одновременно кодировать поля разной гладкости и масштаба. В shared_trunk общие пространственно-временные признаки извлекаются совместно, а различия между u и v частично компенсируются отдельными выходными ветвями, что соответствует более ровкой динамике.




Рисунок 15 – Компоненты функции потерь модели с двумя независимыми нейронными сетями

Эволюция аппроксимации на рисунки 16–18 показывает, что во всех архитектурах поле $u(t, x)$ восстанавливается заметно лучше, чем поле $v(t, x)$. На срезе $t = 0$ все три модели после обучения передают основную структуру фронта. На срезах $t = 2$ и $t = 4$ различия становятся более выраженными: `shared_trunk` лучше сохраняет положение фронта и амплитуду, `two_output` занимает промежуточное положение, а `two_models` демонстрирует наиболее заметное сглаживание переходных зон.

Для поля $v(t, x)$ ни одна из архитектур не воспроизводит с той же точностью узкие знакопеременные пики точного решения на поздних временных срезах. Предсказания остаются сглаженными и имеют заниженную амплитуду, что указывает на трудности восстановления локальной кривизны, связанной с условием $v = u_{xx}$. Та же закономерность отражается и на сводном графике ошибки: минимальную относительную ошибку среди архитектур второго этапа демонстрирует `shared_trunk`, за ним следует `two_output`, тогда как `two_models` показывает наихудший результат.

3.3 Причины деградации точности

Наблюдаемая деградация точности связана со структурой новой задачи оптимизации. Понижение порядка производной устраняет прямое вычисление u_{xxxx} , но заменяет его одновременным обучением двух полей с различной гладкостью. Поле $u(t, x)$ задаёт сравнительно гладкий бегущий фронт, тогда как $v(t, x) = u_{xx}(t, x)$ содержит более локальные и знакопеременные структуры. Поэтому малое локальное отклонение в u усиливается как в аппроксимации v ,




Рисунок 16 – Эволюция аппроксимации гибридной модели с общим стволом




Рисунок 17 – Эволюция аппроксимации модели с двумя выходами

так и в невязке условия согласования формула (3.3).

Эта структура согласуется с общей динамикой обучения. На ранней стадии уменьшение total loss обеспечивается главным образом за счёт снижения ошибок по начальному и граничным условиям и за счёт восстановления грубой формы поля u . После этого дальнейшее уменьшение ошибки требует одновременного снижения residual-компоненты и невязки согласования между u и v , что и приводит к формированию плато.

Архитектурные различия определяются тем, как каждая схема разрешает эту многомасштабную связь. В `two_models` взаимодействие между u и v




Рисунок 18 – Эволюция аппроксимации модели с двумя независимыми нейронными сетями

реализуется только через функционал потерь, поэтому обновление одной сети меняет целевую конфигурацию для другой; это соответствует наиболее выраженным осцилляциям. В `two_output` конфликт ослаблен общим скрытым представлением, но оно должно одновременно кодировать поля разного масштаба. Архитектура `shared_trunk` обеспечивает компромисс между совместным извлечением общих признаков и специализацией выходов, что согласуется с меньшей амплитудой колебаний и более низкой итоговой ошибкой [6; 7].

3.4 Выводы: деградация эффективности при усложнении системы

Результаты второго этапа допускают три основных вывода:

1. Для всех архитектур второго этапа характерно быстрое начальное снижение `total loss`, после которого обучение переходит в режим плато. Лимитирующим фактором при этом становится `residual`-компонента и связанное с ней согласование полей u и v .
2. Понижение порядка за счёт введения переменной v не привело к улучшению точности по сравнению с прямой аппроксимацией исходного уравнения четвёртого порядка. Финальные ошибки моделей второго этапа

остаются примерно на порядок выше, чем у базовой модели первого этапа.

3. Среди рассмотренных архитектур наименьшую итоговую ошибку и наиболее устойчивую динамику обучения демонстрирует `shared_trunk`; архитектура `two_output` занимает промежуточное положение, а `two_models` оказывается наименее устойчивой.

С учётом наблюдаемого дисбаланса между компонентами функции потерь для данной постановки оправдано адаптивное перевзвешивание `residual`- и `boundary`-компонент, а также отдельное масштабирование выходов u и v .

Список литературы

1. Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains / M. Tancik [и др.] // *Advances in Neural Information Processing Systems* 33. — 2020. — С. 7537—7547.
2. *Kuramoto Y.* Diffusion-Induced Chaos in Reaction Systems // *Progress of Theoretical Physics Supplement*. — 1978. — Т. 64. — С. 346—367.
3. On the Spectral Bias of Neural Networks / N. Rahaman [и др.] // *Proceedings of the 36th International Conference on Machine Learning*. Т. 97. — 2019. — С. 5301—5310. — (Proceedings of Machine Learning Research).
4. *Raissi M., Perdikaris P., Karniadakis G. E.* Physics-Informed Neural Networks: A Deep Learning Framework for Solving Forward and Inverse Problems Involving Nonlinear Partial Differential Equations // *Journal of Computational Physics*. — 2019. — Т. 378. — С. 686—707. — DOI: 10.1016/j.jcp.2018.10.045.
5. *Sivashinsky G. I.* Nonlinear Analysis of Hydrodynamic Instability in Laminar Flames—I. Derivation of Basic Equations // *Acta Astronautica*. — 1977. — Т. 4, № 11/12. — С. 1177—1206.
6. *Wang S., Teng Y., Perdikaris P.* Understanding and Mitigating Gradient Flow Pathologies in Physics-Informed Neural Networks // *SIAM Journal on Scientific Computing*. — 2021. — Т. 43, № 5. — A3055—A3081. — DOI: 10.1137/20M1318043.
7. *Wang S., Yu X., Perdikaris P.* When and Why PINNs Fail to Train: A Neural Tangent Kernel Perspective // *Journal of Computational Physics*. — 2022. — Т. 449. — С. 110768. — DOI: 10.1016/j.jcp.2021.110768.