



МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение
высшего образования
«Дальневосточный федеральный университет»

ИНСТИТУТ МАТЕМАТИКИ И КОМПЬЮТЕРНЫХ ТЕХНОЛОГИЙ
Кафедра математического и компьютерного моделирования

Ершова Валерия Константиновна

ТЕОРЕТИКО-СПЕКТРАЛЬНЫЙ АНАЛИЗ АППРОКСИМАЦИОННЫХ
СВОЙСТВ НЕЙРОННЫХ СЕТЕЙ В КОНТЕКСТЕ NEURAL TANGENT
KERNEL (NTK)

КУРСОВАЯ РАБОТА

Направление подготовки 02.03.01 сэт Сквозные цифровые технологии,
бакалавриатская программа «Математика и компьютерные науки»
Очной формы обучения

Студент гр. Б9123-02.03.01 сэт _____
(подпись)

Руководитель _____ Е.В.Амосова
(подпись)

Оценка _____

Регистрационный № _____

(подпись) И.О. Фамилия

(подпись) И.О. Фамилия

«_____» _____ 2026 г.

«_____» _____ 2026 г.

г. Владивосток
2026

В данной работе проводится сравнительный анализ аппроксимационных свойств и спектральных характеристик нейронного касательного ядра для трех архитектур: классической полносвязной сети (FFNN), остаточной сети (ResNet) и сети с Fourier-признаками (Fourier Feature Network). Целью исследования является анализ математических механизмов спектрального смещения и определение влияния структурных параметров ядра на сходимость и точность аппроксимации функций различной сложности.

В ходе экспериментов модели сопоставимой сложности обучались аппроксимировать три класса функций (рисунок 1) различной спектральной сложности: низкочастотную [1], высокочастотную [2] и разрывную [3]. Анализировались собственные значения матрицы NTK, скорость затухания спектра, число обусловленности (κ) и геометрия тепловых карт ядра. Дополнительно исследовалась устойчивость моделей к дегенеративной инициализации (константные веса).




Рисунок 1 – Графики целевых функций:

$$f_1(x) = \sin(x)$$

1 – Низкочастотная функция $f_1(x)$

$$f_2(x) = \sin(10\pi x) + S(15\pi x), \quad \text{где } S(z) = \frac{z}{\pi} - 2 \left\lfloor \frac{z}{2\pi} + \frac{1}{2} \right\rfloor$$

2 – Высокочастотная функция $f_2(x)$

$$f_3(x) = \text{sign}(\sin(5x))$$

3 – Разрывная функция $f_3(x)$

В таблице 1 представлены параметры исследуемых моделей. Они подбирались таким образом, чтобы число обучаемых параметров оставалось в пределах одного порядка (10^5), что позволяет проводить корректное сравнение архитектур при различных уровнях сложности целевых функций.

Таблица 1: Параметры исследуемых моделей

Целевая функция	Модель	Глубина	Параметры	Эпохи
Низкочастотная	FFNN	Depth: 4	$\approx 1.3 \times 10^5$	2 000
	Fourier	Depth: 4	$\approx 1.3 \times 10^5$	1 000
	ResNet	Blocks: 2	$\approx 2.6 \times 10^5$	5 000
Высокочастотная	FFNN	Depth: 6	$\approx 2.6 \times 10^5$	20 000
	Fourier	Depth: 4	$\approx 1.3 \times 10^5$	2 000
	ResNet	Blocks: 4	$\approx 5.3 \times 10^5$	15 000
Разрывная	FFNN	Depth: 6	$\approx 2.6 \times 10^5$	35 000
	Fourier	Depth: 4	$\approx 1.3 \times 10^5$	3 000
	ResNet	Blocks: 5	$\approx 6.6 \times 10^5$	25 000

1. Классические архитектуры (FFNN, ResNet) демонстрируют экспоненциальное затухание собственных значений NTK, работая как фильтры низких частот. Использование Fourier-признаков «выравнивает» спектр, обеспечивая высокую точность аппроксимации высокочастотных и разрывных функций.
2. Fourier-кодирование оптимизирует спектральную структуру задачи, снижая число обусловленности (κ) матрицы NTK на 14–15 порядков, что позволяет ускорять сходимость градиентного спуска и делает процесс обучения устойчивым.
3. Анализ геометрии ядра показал, что NTK Fourier-сети обладает выраженной диагональной структурой. В отличие от глобально коррелированных ядер FFNN/ResNet, это обеспечивает локальность обновлений параметров, позволяя точно восстанавливать разрывы без искажения соседних областей.
4. Кодировщик Fourier-сети предотвращает вырождение сети в один нейрон при неудачной или константной инициализации весов, сохраняя обучаемость модели.

Список литературы

1. Jacot, A. Neural Tangent Kernel: Convergence and Generalization in Neural Networks / A. Jacot, F. Gabriel, C. Hongler. – Текст : непосредственный // Advances in Neural Information Processing Systems (NeurIPS 2018). – 2018. – Vol. 31. – P. 8571–8580. – DOI: 10.48550/arXiv.1806.07572.
2. Cybenko, G. Approximation by superpositions of a sigmoidal function / G. Cybenko. – Текст : непосредственный // Mathematics of Control, Signals and Systems. – 1989. – Vol. 2, № 4. – P. 303–314. – DOI: 10.1007/BF02551274.
3. Rahaman, N. On the spectral bias of neural networks / N. Rahaman, A. Baratin, D. Arpit [et al.]. – Текст : непосредственный // Proceedings of the 36th International Conference on Machine Learning (ICML 2019). – 2019. – Vol. 97. – P. 5301–5310. – DOI: 10.48550/arXiv.1806.08734.
4. Tancik, M. Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains / M. Tancik, P. P. Srinivasan, B. Mildenhall [et al.]. – Текст : непосредственный // Advances in Neural Information Processing Systems (NeurIPS 2020). – 2020. – Vol. 33. – P. 7537–7547. – DOI: 10.48550/arXiv.2006.10739.