

Пятиминутный спич

Добрый день. В своей работе я рассматривала решение уравнения Курамото–Сивашинского методом PINN и анализировала, от чего в этой задаче зависят устойчивость и точность обучения.

1. Проблема и актуальность

Если говорить об актуальности простыми словами, то здесь важна не только сама конкретная модель, но и более общий вопрос. Уравнения математической физики часто содержат одновременно нелинейность, неустойчивость и стабилизирующие механизмы, поэтому они очень чувствительны к численным ошибкам и являются хорошим тестом для современных вычислительных методов. Метод PINN интересен тем, что позволяет учитывать не только данные, но и саму физику задачи через невязку уравнения. Однако на практике остаётся открытым вопрос: всегда ли формальное упрощение постановки действительно улучшает результат. Именно это и стало основной мотивацией моей работы.

2. Постановка задачи

На первом этапе рассматривалось исходное уравнение Курамото–Сивашинского

$$u_t + uu_x + u_{xx} + u_{xxxx} = 0, \quad (1)$$

в одномерной пространственно-временной области с начальными и граничными условиями.

Для этой задачи известно точное аналитическое решение в виде бегущей волны, поэтому можно напрямую сравнивать предсказание сети с точным решением и оценивать качество обучения.

На втором этапе проверялась гипотеза о том, что понижение порядка уравнения может упростить обучение PINN. Для этого была введена вспомогательная переменная

$$v = u_{xx}, \quad (2)$$

и исходная задача была переписана в виде системы

$$u_t + uu_x + v + v_{xx} = 0, \quad (3)$$

$$v - u_{xx} = 0. \quad (4)$$

То есть вместо одного уравнения четвёртого порядка была получена система второго порядка, но уже с двумя неизвестными функциями. Далее сравнивались несколько архитектур нейронных сетей для решения этой системы.

3. Метод решения

Метод решения здесь стандартный для PINN, поэтому подробно останавливаться на нём не буду. Искомая функция, либо пара функций u и v , аппроксимировалась нейронной сетью. Обучение строилось на минимизации составной функции потерь, в которую входили невязка уравнения, начальные условия и граничные условия. Производные вычислялись с помощью автоматического дифференцирования. В базовой модели также использовались нормирование и Фурье-кодирование входов, чтобы лучше передавать пространственные особенности решения.

4. Численный анализ и результаты

Основная часть работы была посвящена именно результатам вычислительного эксперимента.

На первом этапе, где решалось исходное уравнение четвёртого порядка на прямую, базовая модель показала хорошую и достаточно устойчивую сходимости. По мере обучения сеть сначала восстанавливала грубую форму бегущей волны, затем уточняла положение фронта и амплитуду, и к финальным эпохам предсказание практически совпадало с точным решением. Суммарная функция потерь опускалась до порядка 10^{-5} , то есть для исходной постановки PINN сработал качественно.

На втором этапе была протестирована декомпозиция задачи в систему уравнений. В рамках этой декомпозиции были рассмотрены три архитектуры:

- одна сеть с двумя выходами;
- две независимые нейронные сети;
- гибридная архитектура с общим стволом и отдельными выходными ветвями, *shared_trunk*.

И здесь гипотеза о том, что понижение порядка автоматически упростит обучение, не подтвердилась. Во всех трёх вариантах на первых итерациях ошибка быстро уменьшалась, но затем примерно после $3 \cdot 10^3 - 4 \cdot 10^3$ эпох обучение выходило на плато. Финальные значения total loss стабилизировались примерно на уровне

$$1.4 \cdot 10^{-4} - 1.5 \cdot 10^{-4}, \quad (5)$$

то есть примерно на порядок хуже, чем в первом, базовом решении.

Если сравнивать сами архитектуры, то лучший результат среди них показала архитектура *shared_trunk*. Она дала наиболее ровную траекторию обучения и наименьшую итоговую ошибку. Модель с двумя выходами оказалась близка к ней, но с более заметными всплесками. Самой нестабильной оказалась схема с двумя независимыми сетями, где осцилляции были выражены сильнее всего.

Причина такого результата состоит в том, что формально задача стала проще только по порядку производной, но сама задача оптимизации при этом стала сложнее. Вместо одного поля теперь нужно одновременно восстанавливать u и v , причём эти функции имеют разную структуру. Поле u задаёт относительно гладкий бегущий фронт, а поле $v = u_{xx}$ содержит более локальные и знакопеременные пики. Поэтому даже небольшая ошибка в u усиливается при переходе к v , а сети приходится

одновременно удовлетворять и уравнению, и условию согласования

$$v = u_{xx}. \quad (6)$$

Именно из-за этого residual-компонента остаётся лимитирующей, и после быстрого начального этапа обучение упирается в плато.

После этого можно вернуться к первому решению и его НТК-анализу. Для базовой модели первого этапа был проведён анализ нейронного касательного ядра. На репрезентативном батче матрица НТК оказалась полноранговой:

$$\text{rank} = 36, \quad r_{\text{eff}} = 9.73, \quad \kappa \approx 8.15 \cdot 10^2. \quad (7)$$

Спектр собственных значений простирался от 0.627 до 510.49. Это означает, что ядро не вырождается и сохраняет достаточное число рабочих направлений обучения. Кроме того, после обучения в НТК наблюдается выраженная структура: видны локальные кластеры, но при этом сохраняются и межкластерные связи. То есть градиентная информация распространяется по области не хаотично, а достаточно согласованно.

Вывод

Итоговый вывод работы состоит в том, что для PINN решающим оказывается не только порядок дифференциального оператора, но и геометрия самой задачи оптимизации. В рассматриваемой задаче прямая аппроксимация исходного уравнения Курамото–Сивашинского оказалась эффективнее, чем его декомпозиция в систему второго порядка. А НТК-анализ первого решения даёт содержательное объяснение, почему именно базовая постановка обучалась устойчивее.