

Математическая статистика

Формулы и примеры применения

Конспект по материалам `matstat.pdf`

Содержание

1	Вариационные ряды и эмпирическое распределение	3
1.1	Частоты и интервалы	3
1.2	Эмпирическая функция распределения	3
2	Выборочные характеристики	4
2.1	Среднее арифметическое	4
2.2	Мода и медиана	4
2.3	Разброс и вариация	5
3	Выборочные моменты и свойства оценок	7
3.1	Моменты	7
3.2	Свойства оценок	8
3.3	Групповая и общая дисперсии	9
4	Методы точечного оценивания	9
4.1	Метод моментов	9
4.2	Метод максимального правдоподобия	10
5	Доверительные интервалы	11
5.1	Общие определения	11
5.2	Среднее при известной дисперсии	12
5.3	Среднее при неизвестной дисперсии	12

5.4	Доля	13
5.5	Дисперсия	13
6	Статистические гипотезы и критерии проверки	14
6.1	Нулевая и альтернативная гипотезы	14
6.2	Проверка среднего	14
6.3	Проверка дисперсий и согласия	15
7	Корреляционный анализ	16
7.1	Коэффициент Пирсона	16
7.2	Ранговая и согласованность	17
8	Регрессионный анализ	18
8.1	Парная регрессия	18
8.2	Линеаризация нелинейных моделей	20
8.3	Множественная регрессия	20

1 Вариационные ряды и эмпирическое распределение

1.1 Частоты и интервалы

$$w_i = \frac{m_i}{n}$$

Пример применения. Переходит от абсолютной частоты к относительной; показывает долю наблюдений с вариантом x_i .

$$\sum_{i=1}^k m_i = n \quad \sum_{i=1}^k w_i = 1$$

Пример применения. Проверяет полноту таблицы частот и нормировку относительных частот.

$$k \approx 1 + 3,322 \lg n$$

Пример применения. Используется для выбора числа интервалов при построении интервального вариационного ряда.

$$h = \frac{x_{\max} - x_{\min}}{k}$$

Пример применения. Задаёт ширину интервала после того, как число интервалов уже выбрано.

1.2 Эмпирическая функция распределения

$$F_n^*(x) = \frac{1}{n} \sum_{i=1}^n I\{X_i \leq x\}$$

Пример применения. Строит эмпирическую функцию распределения, то есть долю наблюдений, не превосходящих x .

$$F_n^*(x) = \frac{m_x}{n}$$

Пример применения. Удобная запись ЭФР через число элементов выборки, которые лежат левее или на границе x .

2 Выборочные характеристики

2.1 Среднее арифметическое

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Пример применения. Основная оценка центра выборки; показывает средний уровень признака.

$$\bar{x} = \frac{\sum_{i=1}^k x_i^* m_i}{\sum_{i=1}^k m_i} = \frac{\sum_{i=1}^k x_i^* m_i}{n}$$

Пример применения. Та же формула для вариационного ряда с частотами; используется, когда данные уже сгруппированы.

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

Пример применения. Показывает, что положительные и отрицательные отклонения от среднего взаимно компенсируются.

$$\sum_{i=1}^k m_i (x_i^* - \bar{x}) = 0$$

Пример применения. То же свойство для данных, записанных с частотами.

2.2 Мода и медиана

$$Mo = x_j, \quad m_j = \max_i m_i$$

Пример применения. Для дискретного ряда находит наиболее часто встречающееся значение признака.

$$Mo = x_0 + \frac{m_0 - m_{-1}}{(m_0 - m_{-1}) + (m_0 - m_{+1})} h$$

Пример применения. Приближённо вычисляет моду для интервального ряда по модальному интервалу.

$$Me = \begin{cases} x_{(n+1)/2}, & n \text{ нечётно,} \\ \frac{x_{(n/2)} + x_{(n/2+1)}}{2}, & n \text{ чётно.} \end{cases}$$

Пример применения. Находит медиану дискретного упорядоченного ряда.

$$Me = x_0 + \frac{0,5n - n_{Me-1}}{m_{Me}} h$$

Пример применения. Приближённо вычисляет медиану для интервального ряда.

2.3 Разброс и вариация

$$R = x_{\max} - x_{\min}$$

Пример применения. Даёт самый простой показатель разброса: расстояние между крайними значениями выборки.

$$d = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

Пример применения. Считает среднее линейное отклонение от среднего.

$$d = \frac{\sum_{i=1}^k m_i |x_i^* - \bar{x}|}{\sum_{i=1}^k m_i}$$

Пример применения. Та же характеристика для данных, сгруппированных по значениям.

$$D = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Пример применения. Выборочная дисперсия: измеряет средний квадрат отклонений от среднего.

$$D = \frac{\sum_{i=1}^k m_i (x_i^* - \bar{x})^2}{\sum_{i=1}^k m_i}$$

Пример применения. Формула дисперсии для вариационного ряда с частотами.

$$D = \overline{x^2} - (\bar{x})^2, \quad \overline{x^2} = \frac{1}{n} \sum_{i=1}^n x_i^2$$

Пример применения. Удобная вычислительная формула для дисперсии; обычно быстрее считать через квадраты.

$$\sigma_v = \sqrt{D}$$

Пример применения. Среднее квадратическое отклонение, то есть корень из дисперсии; измеряется в тех же единицах, что и исходные данные.

$$S^2 = \frac{n}{n-1} D = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Пример применения. Исправленная выборочная дисперсия; применяется как несмещённая оценка генеральной дисперсии.

$$S = \sqrt{S^2}$$

Пример применения. Исправленное среднее квадратическое отклонение; используется, когда нужна несмещённая оценка разброса.

$$d_Q = \frac{Q_3 - Q_1}{2}$$

Пример применения. Квартильное отклонение: показывает разброс центральной половины данных.

$$V = \frac{S}{\bar{x}} \cdot 100\%$$

Пример применения. Коэффициент вариации; позволяет сравнивать относительную изменчивость разных выборок.

3 Выборочные моменты и свойства оценок

3.1 Моменты

$$\nu_r = \frac{1}{n} \sum_{i=1}^n x_i^r$$

Пример применения. Начальный выборочный момент порядка r ; используется для описания формы распределения и в методе моментов.

$$\nu_r = \frac{\sum_{i=1}^k m_i (x_i^*)^r}{\sum_{i=1}^k m_i}$$

Пример применения. Та же формула для сгруппированных данных с частотами.

$$\mu_r = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^r$$

Пример применения. Центральный выборочный момент порядка r ; нужен для оценки разброса, асимметрии и эксцесса.

$$\mu_r = \frac{\sum_{i=1}^k m_i (x_i^* - \bar{x})^r}{\sum_{i=1}^k m_i}$$

Пример применения. Центральный момент для вариационного ряда с частотами.

$$\mu_2 = D$$

Пример применения. Связывает второй центральный момент с дисперсией.

3.2 Свойства оценок

$$\mathbb{E}(\hat{\theta}) = \theta$$

Пример применения. Условие несмещённости оценки.

$$\hat{\theta} \xrightarrow{P} \theta$$

Пример применения. Условие состоятельности оценки: при росте объёма выборки оценка сходится к истинному параметру.

$$\mathbb{E}\bar{X} = a$$

Пример применения. Показывает, что выборочное среднее является несмещённой оценкой математического ожидания.

$$D\bar{X} = \frac{\sigma^2}{n}$$

Пример применения. Показывает, что разброс выборочного среднего уменьшается при росте объёма выборки.

$$\mathbb{E}D = \frac{n-1}{n}\sigma^2$$

Пример применения. Показывает смещение обычной выборочной дисперсии.

$$\mathbb{E}S^2 = \sigma^2$$

Пример применения. Доказывает, что исправленная дисперсия является несмещённой оценкой генеральной дисперсии.

3.3 Групповая и общая дисперсии

$$\bar{x} = \frac{\sum_j N_j \bar{x}_j}{N}$$

Пример применения. Находит общее среднее по группам, если совокупность предварительно разбита на классы.

$$D_{\text{гр}} = \frac{\sum_j N_j D_j}{N}$$

Пример применения. Средняя из внутригрупповых дисперсий; показывает разброс внутри групп.

$$D_{\text{меж}} = \frac{\sum_j N_j (\bar{x}_j - \bar{x})^2}{N}$$

Пример применения. Межгрупповая дисперсия; отражает различия между средними групп.

$$D_{\text{общ}} = \frac{\sum_j \sum_i (x_{ij} - \bar{x})^2}{N}$$

Пример применения. Общая дисперсия для всей совокупности.

$$D_{\text{общ}} = D_{\text{гр}} + D_{\text{меж}}$$

Пример применения. Правило сложения дисперсий: общая изменчивость раскладывается на внутригрупповую и межгрупповую части.

4 Методы точечного оценивания

4.1 Метод моментов

$$\begin{cases} \mathbb{E}_{\theta} X = \nu_1, \\ \mathbb{E}_{\theta} X^2 = \nu_2, \\ \vdots \\ \mathbb{E}_{\theta} X^m = \nu_m \end{cases}$$

Пример применения. Система метода моментов: теоретические моменты приравняются к выборочным, чтобы получить оценки параметров.

$$\mathbb{E}X = \frac{\theta}{2}, \quad \hat{\theta} = 2\bar{X}$$

Пример применения. Пример метода моментов для равномерного распределения $U(0, \theta)$ по первому моменту.

$$\mathbb{E}X^2 = \frac{\theta^2}{3}, \quad \hat{\theta} = \sqrt{3\bar{X}^2}$$

Пример применения. Пример метода моментов для $U(0, \theta)$ по второму моменту.

$$\mathbb{E}X = \frac{1}{\lambda}, \quad \hat{\lambda} = \frac{1}{\bar{X}}$$

Пример применения. Пример метода моментов для экспоненциального распределения.

4.2 Метод максимального правдоподобия

$$L(\theta) = \prod_{i=1}^n f(x_i, \theta)$$

Пример применения. Функция правдоподобия: показывает, насколько хорошо параметр θ объясняет наблюденную выборку.

$$\hat{\theta} = \arg \max_{\theta \in \Theta} L(\theta)$$

Пример применения. Определение оценки максимального правдоподобия.

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^n \ln f(x_i, \theta)$$

Пример применения. Логарифм правдоподобия; его обычно максимизируют вместо самой функции правдоподобия.

$$\frac{d\ell(\theta)}{d\theta} = 0$$

Пример применения. Уравнение, которое решают для поиска точки максимума, если параметр один.

$$\frac{\partial \ell}{\partial \theta_j} = 0, \quad j = 1, \dots, m$$

Пример применения. Система условий максимума для случая нескольких параметров.

$$f(x, \theta) = \frac{1}{\theta}, \quad 0 \leq x \leq \theta$$

Пример применения. Плотность равномерного распределения $U(0, \theta)$, нужная для вывода МП-оценки.

$$L(\theta) = \frac{1}{\theta^n} I\{\theta \geq x_{(n)}\}$$

Пример применения. Правдоподобие для $U(0, \theta)$; используется для получения оценки $\hat{\theta} = x_{(n)}$.

$$\hat{\theta} = x_{(n)}$$

Пример применения. Оценка максимального правдоподобия для параметра θ в равномерном распределении $U(0, \theta)$.

5 Доверительные интервалы

5.1 Общие определения

$$P(\theta_1 < \theta < \theta_2) = \gamma$$

Пример применения. Определяет смысл доверительного интервала: параметр попадает в интервал с вероятностью γ .

$$\alpha = 1 - \gamma$$

Пример применения. Связывает доверительную вероятность и уровень значимости.

5.2 Среднее при известной дисперсии

$$Z = \frac{\bar{X} - a}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Пример применения. Переход к стандартному нормальному закону при известной дисперсии.

$$\bar{X} - u_\gamma \frac{\sigma}{\sqrt{n}} < a < \bar{X} + u_\gamma \frac{\sigma}{\sqrt{n}}$$

Пример применения. Доверительный интервал для математического ожидания при известной дисперсии.

$$n \geq \frac{u_\gamma^2 \sigma^2}{\Delta^2}$$

Пример применения. Формула для оценки требуемого объема выборки при заданной предельной ошибке.

5.3 Среднее при неизвестной дисперсии

$$t = \frac{\bar{X} - a}{S/\sqrt{n}}$$

Пример применения. Статистика Стьюдента, когда дисперсия неизвестна и заменяется исправленным стандартным отклонением.

$$\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} < a < \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}$$

Пример применения. Доверительный интервал для математического ожидания при неизвестной дисперсии.

5.4 Доля

$$\hat{p} = \frac{m}{n}, \quad \hat{q} = 1 - \hat{p}$$

Пример применения. Выборочная доля и дополнение к ней; используются при построении интервала для вероятности события.

$$\hat{p} - u_\gamma \sqrt{\frac{\hat{p}\hat{q}}{n}} < p < \hat{p} + u_\gamma \sqrt{\frac{\hat{p}\hat{q}}{n}}$$

Пример применения. Приближённый доверительный интервал для доли в большой выборке.

$$\Delta = u_\gamma \sqrt{\frac{\hat{p}\hat{q}}{n}}$$

Пример применения. Формула предельной ошибки для оценки доли.

$$n \geq \frac{u_\gamma^2 pq}{\Delta^2}$$

Пример применения. Оценка необходимого объёма выборки, если заранее известны p и q .

$$n \geq \frac{u_\gamma^2}{4\Delta^2}$$

Пример применения. Худший случай для оценки объёма выборки, когда p заранее неизвестно.

5.5 Дисперсия

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2}$$

Пример применения. Статистика хи-квадрат для нормальной совокупности; используется при построении интервала для дисперсии.

$$\frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} < \sigma^2 < \frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}$$

Пример применения. Доверительный интервал для генеральной дисперсии.

6 Статистические гипотезы и критерии проверки

6.1 Нулевая и альтернативная гипотезы

$$H_0 : a = a_0 \quad H_1 : a \neq a_0$$

Пример применения. Типичный вид гипотезы о среднем в двусторонней постановке.

$$H_0 : \sigma_X^2 = \sigma_Y^2 \quad H_1 : \sigma_X^2 \neq \sigma_Y^2$$

Пример применения. Гипотеза о равенстве дисперсий двух совокупностей.

6.2 Проверка среднего

$$Z = \frac{\bar{X} - a_0}{\sigma/\sqrt{n}}$$

Пример применения. Статистика для проверки гипотезы о среднем, когда дисперсия известна.

$$|Z_{\text{набл}}| > u_{1-\alpha/2}$$

Пример применения. Правило отклонения нулевой гипотезы для двустороннего z-критерия.

$$t = \frac{\bar{X} - a_0}{S/\sqrt{n}}$$

Пример применения. Статистика для проверки среднего при неизвестной дисперсии.

$$|t_{\text{набл}}| > t_{\alpha/2, n-1}$$

Пример применения. Правило отклонения нулевой гипотезы для двустороннего t-критерия.

$$t = \frac{\bar{X} - \bar{Y}}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}, \quad S_p^2 = \frac{(n_1 - 1)S_X^2 + (n_2 - 1)S_Y^2}{n_1 + n_2 - 2}$$

Пример применения. Критерий для сравнения двух независимых средних при равных, но неизвестных дисперсиях.

$$k = n_1 + n_2 - 2$$

Пример применения. Число степеней свободы в двухвыборочном t-критерии.

$$d_i = x_i - y_i, \quad t = \frac{\bar{d}}{S_d / \sqrt{n}}$$

Пример применения. Парный t-критерий: сначала считают разности, затем проверяют гипотезу о нулевом среднем разностей.

6.3 Проверка дисперсий и согласия

$$F = \frac{S_X^2}{S_Y^2}$$

Пример применения. Статистика критерия Фишера–Снедекора для проверки равенства дисперсий.

$$\chi_{\text{набл}}^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i}$$

Пример применения. Критерий согласия Пирсона: сравнивает наблюдаемые и теоретические частоты.

$$\nu = k - 1$$

Пример применения. Число степеней свободы в критерии Пирсона, если параметры распределения не оценивались по выборке.

$$\nu = k - m - 1$$

Пример применения. Число степеней свободы в критерии Пирсона, если по выборке оценивалось m параметров.

$$\hat{n}_{ij} = \frac{n_{i \cdot} n_{\cdot j}}{n}$$

Пример применения. Ожидаемая частота в таблице сопряжённости при условии независимости признаков.

$$\chi^2_{\text{набл}} = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - \hat{n}_{ij})^2}{\hat{n}_{ij}}$$

Пример применения. Критерий независимости признаков по таблице сопряжённости.

$$\nu = (r - 1)(c - 1)$$

Пример применения. Число степеней свободы в критерии независимости.

7 Корреляционный анализ

7.1 Коэффициент Пирсона

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Пример применения. Измеряет тесноту линейной связи между двумя количественными признаками.

$$r_{xy} = \frac{\overline{xy} - \bar{x}\bar{y}}{\sigma_x \sigma_y}$$

Пример применения. Эквивалентная вычислительная форма коэффициента корреляции Пирсона.

$$t_{\text{набл}} = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

Пример применения. Статистика для проверки значимости коэффициента корреляции.

$$|t_{\text{набл}}| > t_{\alpha/2, n-2}$$

Пример применения. Правило отклонения гипотезы об отсутствии линейной корреляции.

7.2 Ранговая и согласованность

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

Пример применения. Коэффициент ранговой корреляции Спирмена; применяется для ранговых данных.

$$t = \frac{r_s \sqrt{n-2}}{\sqrt{1-r_s^2}}$$

Пример применения. Приближённая проверка значимости ранговой корреляции Спирмена.

$$S = \sum_{i=1}^n (R_i - \bar{R})^2$$

Пример применения. Промежуточная сумма квадратов отклонений рангов в коэффициенте конкордации Кендалла.

$$W = \frac{12S}{m^2(n^3 - n)}$$

Пример применения. Коэффициент конкордации Кендалла; измеряет согласованность мнений экспертов.

$$\chi_{\text{набл}}^2 = m(n-1)W$$

Пример применения. Статистика для проверки значимости коэффициента конкордации.

8 Регрессионный анализ

8.1 Парная регрессия

$$y = f(x) + \varepsilon$$

Пример применения. Общая запись регрессии: наблюдаемое значение состоит из систематической части и случайной ошибки.

$$y = a + bx + \varepsilon$$

Пример применения. Линейная парная регрессия; подходит, когда связь между признаками близка к прямой.

$$Q(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2 \rightarrow \min$$

Пример применения. Метод наименьших квадратов: параметры выбирают так, чтобы сумма квадратов ошибок была минимальной.

$$\begin{cases} na + b \sum x_i = \sum y_i, \\ a \sum x_i + b \sum x_i^2 = \sum x_i y_i \end{cases}$$

Пример применения. Нормальные уравнения метода наименьших квадратов для линейной регрессии.

$$b = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - (\bar{x})^2}, \quad a = \bar{y} - b\bar{x}$$

Пример применения. Явная формула для оценок коэффициентов линейной регрессии.

$$r_{xy} = \frac{b\sigma_x}{\sigma_y}$$

Пример применения. Связывает наклон линейной регрессии с коэффициентом корреляции.

$$R^2 = \frac{\sum(\hat{y}_i - \bar{y})^2}{\sum(y_i - \bar{y})^2}$$

Пример применения. Коэффициент детерминации: показывает долю объяснённой вариации результата.

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

Пример применения. Эквивалентная форма коэффициента детерминации через остатки.

$$R^2 = r_{xy}^2$$

Пример применения. Для парной линейной регрессии коэффициент детерминации равен квадрату корреляции.

$$F_{\text{набл}} = \frac{R^2}{1 - R^2}(n - 2)$$

Пример применения. Критерий Фишера для проверки значимости парной линейной регрессии.

$$F_{\text{набл}} = \frac{R^2/p}{(1 - R^2)/(n - p - 1)}$$

Пример применения. Критерий Фишера для множественной линейной регрессии.

$$F_{\text{набл}} > F_{\alpha, p, n-p-1}$$

Пример применения. Правило отклонения нулевой гипотезы о незначимости регрессии.

8.2 Линеаризация нелинейных моделей

$$y = a + bx + cx^2 \Rightarrow z = x^2, \quad y = a + bx + cz,$$

$$y = ab^x \Rightarrow \ln y = \ln a + x \ln b, \quad Y = A + Bx,$$

$$y = ax^b \Rightarrow \ln y = \ln a + b \ln x, \quad Y = A + BX,$$

$$y = ae^{bx} \Rightarrow \ln y = \ln a + bx, \quad Y = A + bx,$$

$$y = a + b \ln x \Rightarrow X = \ln x, \quad y = a + bX$$

Пример применения. Эта схема показывает, как нелинейную зависимость сводят к линейной заменой переменных и затем решают обычную задачу МНК.

8.3 Множественная регрессия

$$y = b_0 + b_1x_1 + b_2x_2 + \dots + b_px_p + \varepsilon$$

Пример применения. Множественная линейная регрессия: результат зависит сразу от нескольких факторов.

$$\mathbf{y} = \mathbf{X}\mathbf{b} + \varepsilon$$

Пример применения. Матричная форма записи множественной регрессии.

$$\hat{\mathbf{b}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Пример применения. Матричная формула МНК для оценки коэффициентов множественной регрессии.

$$\begin{cases} nb_0 + b_1 \sum x_1 + b_2 \sum x_2 = \sum y, \\ b_0 \sum x_1 + b_1 \sum x_1^2 + b_2 \sum x_1x_2 = \sum x_1y, \\ b_0 \sum x_2 + b_1 \sum x_1x_2 + b_2 \sum x_2^2 = \sum x_2y \end{cases}$$

Пример применения. Нормальные уравнения для регрессии с двумя факторами.

Краткий итог

Формулы из `matstat.pdf` используются для трёх основных задач:

- описать выборку и её разброс;
- оценить неизвестные параметры генеральной совокупности;
- проверить гипотезы и построить модели зависимости между признаками.